# R

Redes **Neurais Artificiais** 

\*Aula 03







#### THE ROAD SO FAR





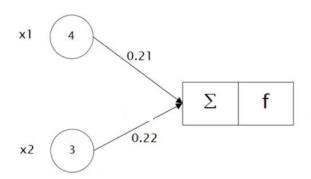
**UNIVERSIDADE**DO ESTADO DE MINAS GERAIS

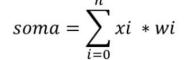


#### classificação

x1 - comprimento do parafuso x2 - diâmetro do parafuso

Classe A (0) e Classe B (1)

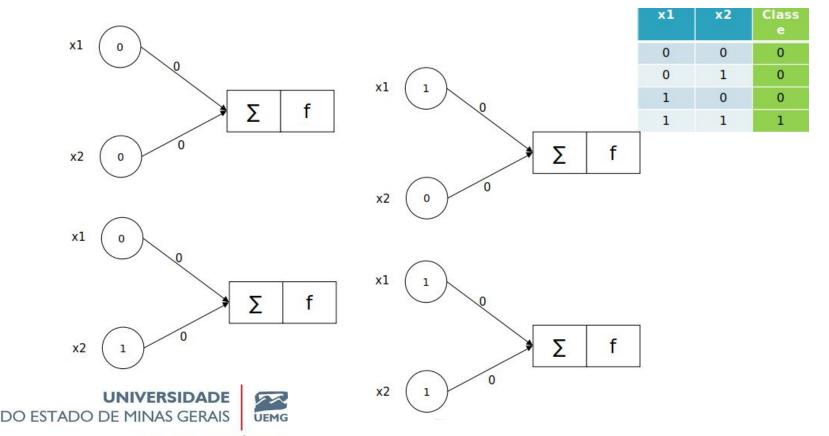






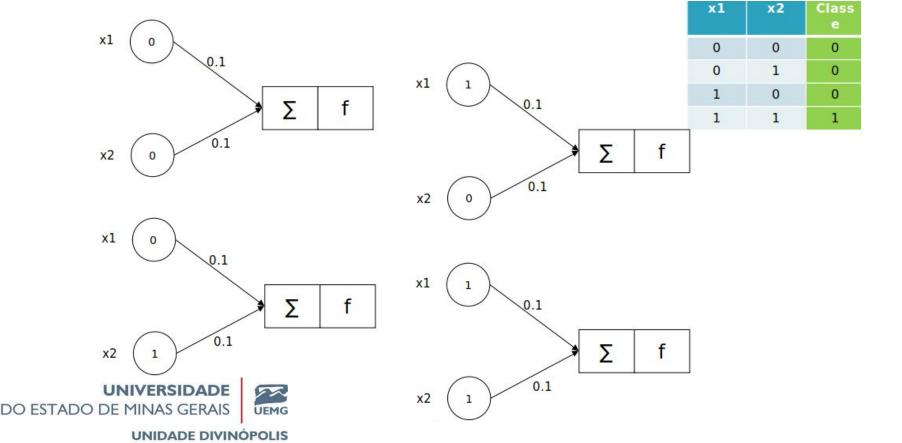
#### Operador E

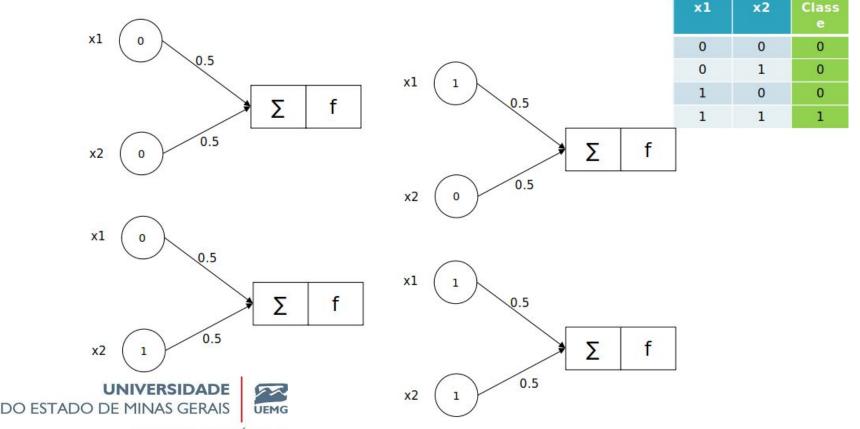
<b>x1</b>	x2	Classe
0	0	0
0	1	0
1	0	0
1	1	1

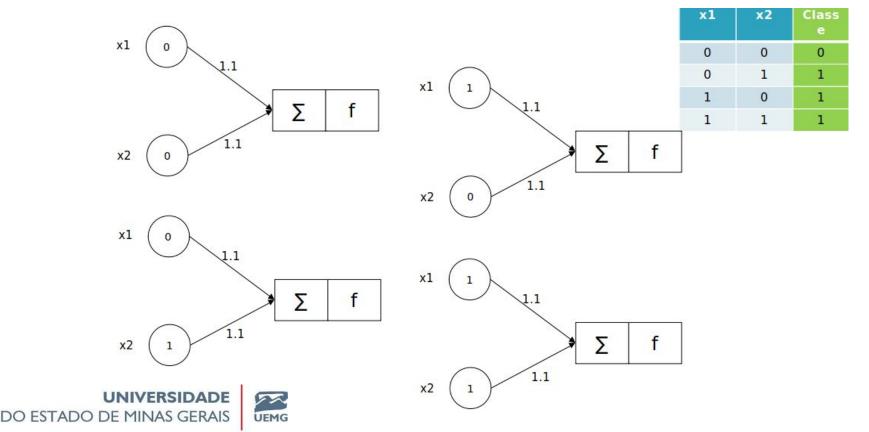


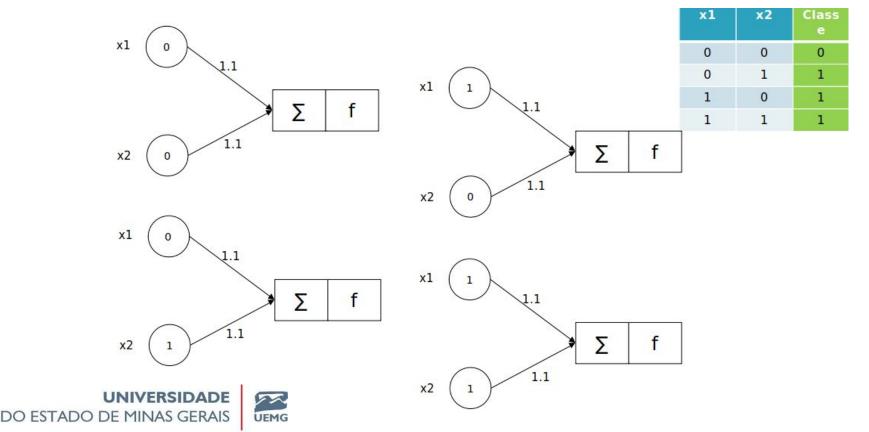
#### Algoritmo mais simples

- erro = respostaCorreta respostaCalculada
   Os pesos são atualizados até os erros serem
   pequenos
- peso(n + 1) = peso(n) + (taxaAprendizagem \* entrada \* erro)



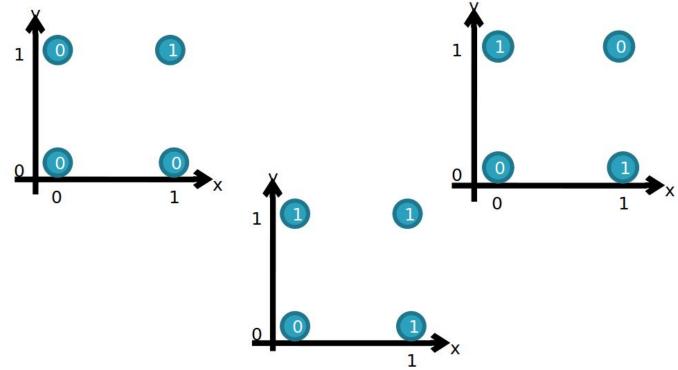






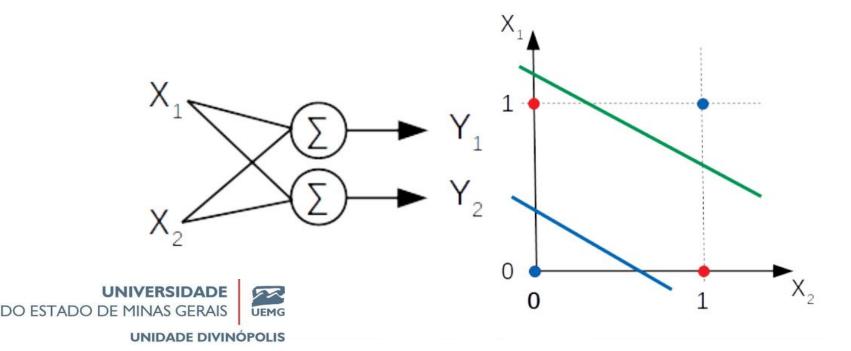
#### Enquanto o erro for diferente de zero

- Para cada registro
  - Calcula a saída com os pesos atuais
  - Compara a saída esperada com a saída calculada, somando o erro
  - Para cada peso da rede
    - Atualiza o peso peso(n + 1) = peso(n) + (taxaAprendizagem \* entrada \* erro)

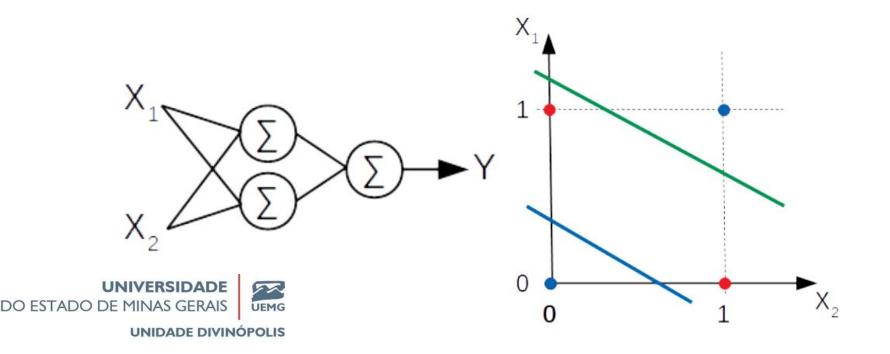




- Como resolver problemas que n\u00e3o s\u00e3o linearmente separ\u00e1veis?
- Aumentar o número de neurônios resolve? Não!

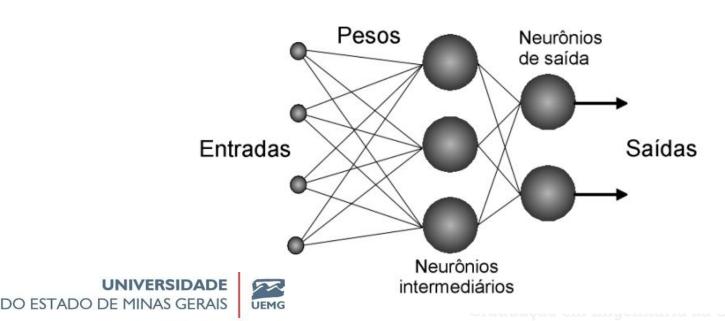


A solução é aumentar o número de camadas de neurônios.

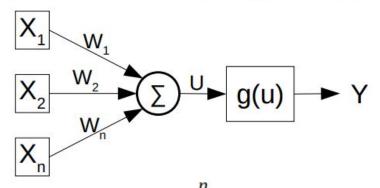


UNIDADE DIVINÓPOLIS

As redes neurais mais modernas são compostas por múltiplas camadas de neurônios e possibilitam a resolução de problemas não linearmente separáveis.



Para o modelo de neurônio a seguir temos:

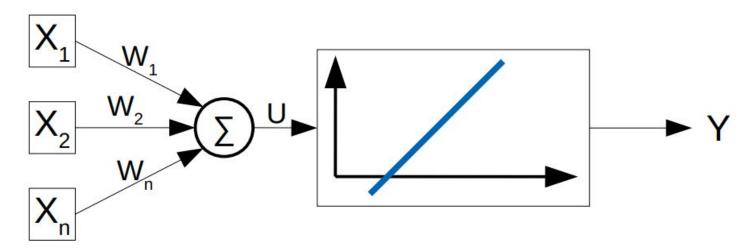


- Potencial de ativação:  $u = \sum_{i=1}^{n} W_i \cdot X_i$
- Função de ativação: g(). (função degrau nos exemplos anteriores)

• Assim: 
$$Y = g(u) = g\left(\sum_{i=1}^{n} W_i \cdot X_i\right)$$



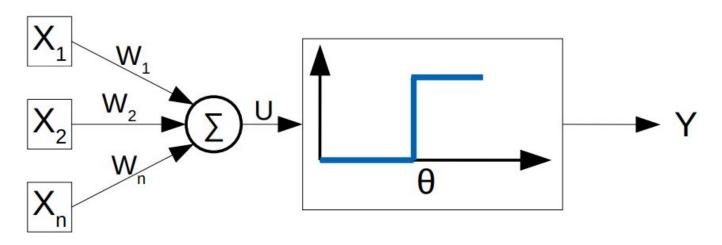
Função Linear



$$Y = \gamma \left( \sum_{i=1}^{n} W_{i} \cdot X_{i} \right) = \gamma u$$

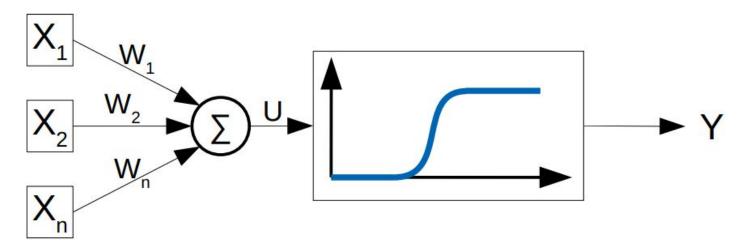


Função Degrau



$$Y = \begin{cases} 1 & se(u \ge \theta) \\ & \text{onde,} \quad u = \left(\sum_{i=1}^{n} W_i \cdot X_i\right) \\ 0 & se(u < \theta) \end{cases}$$

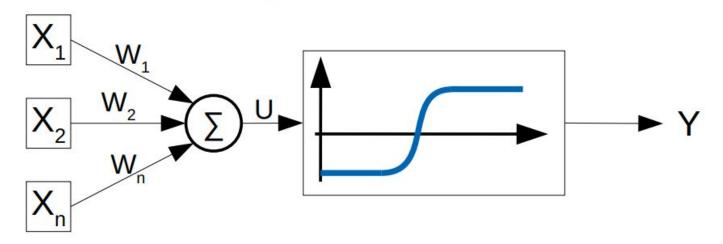
Função Sigmoidal



$$Y = \frac{1}{1 + e^{-u}} \quad onde, u = \left(\sum_{i=1}^{n} W_i \cdot X_i\right)$$
DO ESTADO DE MINAS GERAIS

#### funcões de ativacão

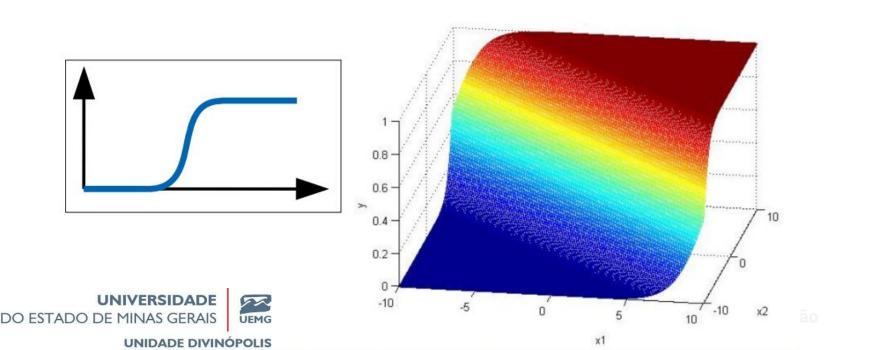
Função Tangente Hiperbólica



$$Y = \frac{e^{u} - e^{-u}}{e^{u} + e^{-u}} \quad onde, u = \left(\sum_{i=1}^{n} W_{i} \cdot X_{i}\right)$$
DO ESTADO DE MINAS GERAIS

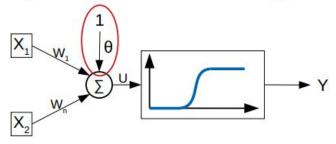
DO ESTADO DE MINAS GERAIS

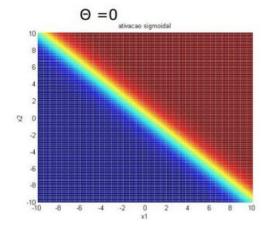
Mapeamento de entrada para saída em um neurônio com função de ativação sigmoidal.

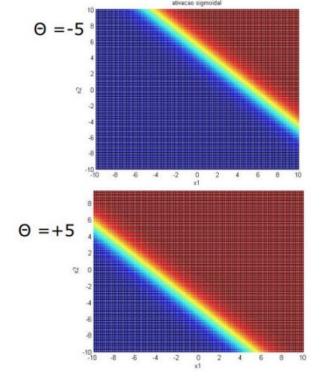


Uma entrada especial chamada **Bias** é utilizada para

ajustar o limiar de atuação.



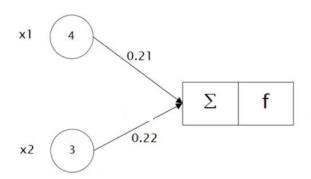


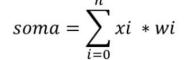


#### classificação

x1 - comprimento do parafuso x2 - diâmetro do parafuso

Classe A (0) e Classe B (1)

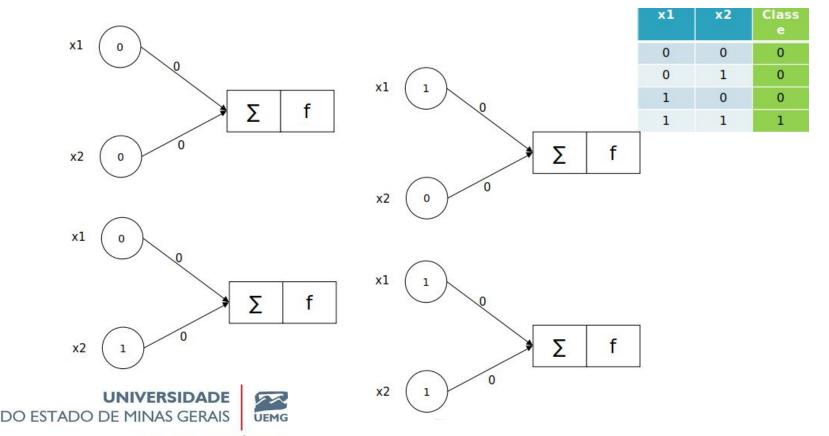






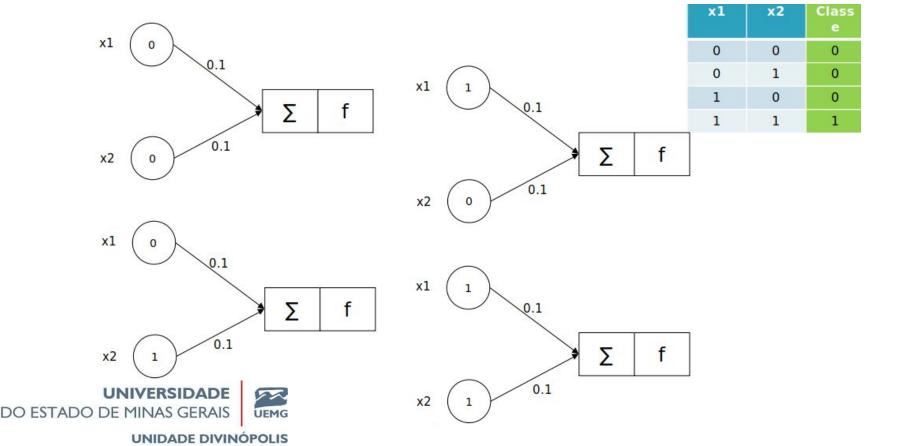
#### Operador E

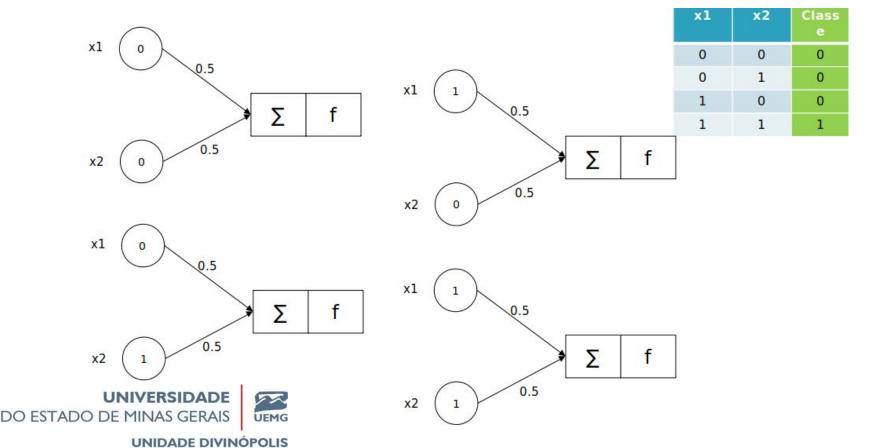
<b>x1</b>	x2	Classe
0	0	0
0	1	0
1	0	0
1	1	1

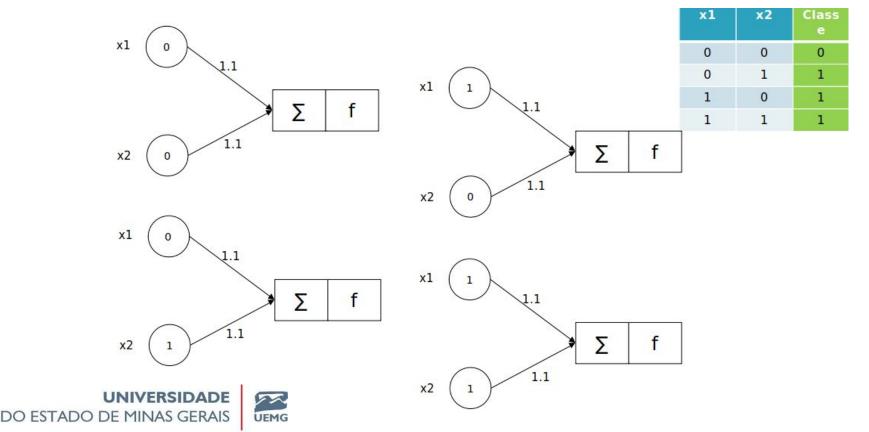


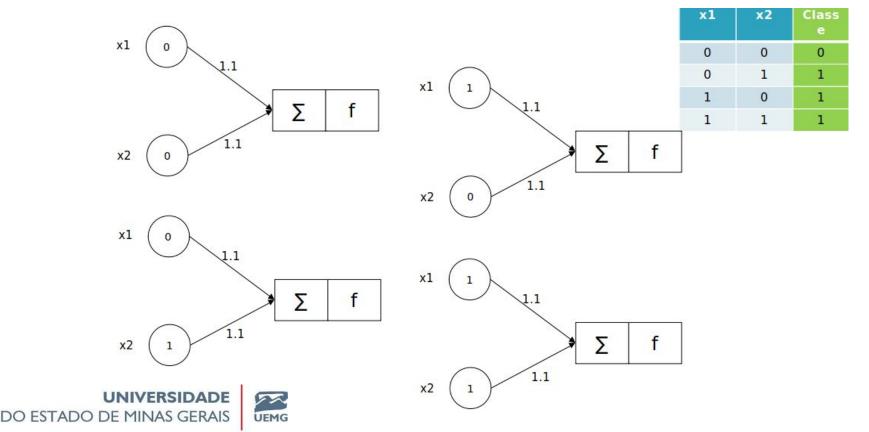
#### Algoritmo mais simples

- erro = respostaCorreta respostaCalculada
   Os pesos são atualizados até os erros serem
   pequenos
- peso(n + 1) = peso(n) + (taxaAprendizagem \* entrada \* erro)









#### Enquanto o erro for diferente de zero

- Para cada registro
  - Calcula a saída com os pesos atuais
  - Compara a saída esperada com a saída calculada, somando o erro
  - Para cada peso da rede
    - Atualiza o peso peso(n + 1) = peso(n) + (taxaAprendizagem \* entrada \* erro)

